

Машинное обучение в финансах

Лекция 4: Осторожный (risk-averse) RL

Игорь Удовиченко

Факультатив Веги

17 апреля 2026 г.

План лекции

1. Мотивация
2. Теория полезности
3. Теория осторожного RL
4. Deep Hedging

План лекции

1. Мотивация

2. Теория полезности

3. Теория осторожного RL

4. Deep Hedging

Напоминание: классический RL в хеджировании

На прошлой лекции: хеджирование деривативов как MDP. Целевой функционал — ожидаемый P&L портфеля:

$$J(\pi) = \mathbb{E} \left[\sum_{t=0}^{T-1} h_t(S_{t+1} - S_t) + c(S_T) \right] \rightarrow \max_{\pi}$$

Проблема. При наличии дрифта $\mathbb{E}[S_{t+1} - S_t \mid S_t] = \mu_t \neq 0$:

- Оптимальное действие $h_t^* = \pm\infty$ (знак совпадает со знаком μ_t)
- $J(\pi^*) = +\infty$, $V^*(s) \equiv +\infty$ — задача вырождена
- Q-learning сойдётся к $Q^* = +\infty$; policy gradient раздувает $|h_t|$

Агент не хеджирует, а неограниченно спекулирует на дрифте.

Вывод: максимизация $\mathbb{E}[R]$ — не та цель. Хеджер хочет *контролировать риск*, а не максимизировать среднюю прибыль втую.

План лекции

1. Мотивация

2. Теория полезности

3. Теория осторожного RL

4. Deep Hedging

Предпочтения и аксиомы полезности

Как формализовать, что случайный исход X предпочтительнее Y ?

X, Y — случайные величины (лотереи) со значениями в $\mathbb{R}$. **Отношение предпочтения** $\succeq$: $X \succeq Y$ означает « X не хуже Y ».

Аксиомы фон Неймана–Моргенштерна:

1. *Полнота*: $\forall X, Y$: либо $X \succeq Y$, либо $Y \succeq X$
2. *Транзитивность*: $X \succeq Y, Y \succeq Z \Rightarrow X \succeq Z$
3. *Непрерывность*: $X \succeq Y \succeq Z \Rightarrow \exists p \in [0, 1]: pX + (1 - p)Z \sim Y$
4. *Независимость*: $X \succ Y \Rightarrow \forall Z, p \in (0, 1): pX + (1 - p)Z \succ pY + (1 - p)Z$

Теорема (фон Нейман–Моргенштерн).

$\succeq$ удовлетворяет аксиомам 1–4 $\iff$ существует **функция полезности** $u: \mathbb{R} \rightarrow \mathbb{R}$ (единственная с точностью до аффинного преобразования $u \mapsto \alpha u + \beta, \alpha > 0$):

$$X \succeq Y \iff \mathbb{E}[u(X)] \geq \mathbb{E}[u(Y)]$$

Свойства функции полезности

Следствия теоремы фон Неймана–Моргенштерна:

1. **Аффинная единственность.** u и $\alpha u + \beta$ ($\alpha > 0$) задают одни и те же предпочтения $\Rightarrow$ можно нормализовать.
2. **Монотонность.** «Не бывает слишком много денег»: u возрастающая.
3. **Осторожность $\iff$ вогнутость.** Агент *осторожный*, если детерминированный исход $\mathbb{E}[X]$ не хуже самой лотереи X :

$$\mathbb{E}[u(X)] \leq u(\mathbb{E}[X]) \quad \forall X \quad \overset{\text{Йенсен}}{\iff} \quad u \text{ — вогнутая}$$

Риск-нейтральный: u линейна. *азартный*: u выпукла.

4. **Денежный эквивалент** (certainty equivalent): $\text{CE}(X) := u^{-1}(\mathbb{E}[u(X)])$.

Сумма наличных, эквивалентная лотерее X . Для осторожного агента $\text{CE}(X) \leq \mathbb{E}[X]$; разность $\mathbb{E}[X] - \text{CE}(X) \geq 0$ — *премия за риск*.

CARA и CRRA

Коэффициент абсолютной осторожности (Arrow–Pratt): $A(x) := -u''(x)/u'(x)$.

Локальная мера кривизны; инвариантен к аффинному преобразованию u .

CARA (Constant Absolute Risk Aversion): $A(x) \equiv \alpha > 0$. Решая ОДУ, с точностью до аффинного преобразования получаем *экспоненциальную полезность*:

$$\boxed{u(x) = -e^{-\alpha x}} \quad x \in \mathbb{R}$$

Коэффициент относительной осторожности: $RRA(x) := -x u''(x)/u'(x)$.

CRRA (Constant Relative Risk Aversion): $RRA(x) \equiv \eta$ для $x > 0$. Аналогично — *степенная полезность*:

$$u(x) = \begin{cases} x^{1-\eta}/(1-\eta), & \eta \neq 1 \\ \log x, & \eta = 1 \end{cases} \quad x > 0$$

Определена только на $x > 0 \Rightarrow$ моделирует *богатство*, но не P&L (который может быть отрицательным).

Cash invariance и экспоненциальная полезность

Cash invariance (денежная инвариантность): $CE(X + c) = CE(X) + c \quad \forall c \in \mathbb{R}$.
Сдвиг выплат на детерминированную сумму сдвигает эквивалент на ту же сумму.

Теорема.

CE_u cash invariant $\iff u$ — экспоненциальная полезность $u(x) = -e^{-\alpha x}$
(с точностью до аффинного преобразования; $\alpha \rightarrow 0$ — линейный случай).

Идея доказательства. Сведение к уравнению Коши $a(x_1 + x_2) = a(x_1) + a(x_2)$.

Почему cash invariance разумна в торговле деривативами:

- P&L принимает значения на всём $\mathbb{R} \Rightarrow$ CRRA неприменима
- Детерминированные потоки (премии, комиссии) не должны менять стратегию хеджирования — только сдвигать значение функционала

Дескриптивная и прескриптивная интерпретации

Теорема даёт представление предпочтений. Но откуда берутся сами аксиомы?

Дескриптивная (как *есть*): *реальные люди* максимизируют $\mathbb{E}[u(X)]$ для некоторой u .

- Эмпирически **неверна**: различные парадоксы — систематические нарушения аксиомы независимости
- Канеман и Тверски (1979): *prospect theory* — люди искажают вероятности и асимметрично реагируют на прибыль/убыток (Нобелевская премия 2002)

Прескриптивная (как *должно быть*): аксиомы — не эмпирические факты, а требования к *рациональному* агенту. Тогда рациональный выбор = максимизация $\mathbb{E}[u(X)]$ при некоторой u .

В финансах и RL используем прескриптивно:

- Выбираем u — так кодируем отношение к риску
- Целевой функционал: $\mathbb{E}[u(R(\mathcal{T}))] \rightarrow \max_{\pi}$

План лекции

1. Мотивация

2. Теория полезности

3. Теория осторожного RL

4. Deep Hedging

Энтропийный денежный эквивалент

Для экспоненциальной полезности $u(x) = -e^{-\alpha x}$ денежный эквивалент имеет явный вид: $CE(X) = u^{-1}(\mathbb{E}[u(X)]) = -\alpha^{-1} \log \mathbb{E}[e^{-\alpha X}]$.

Введём обозначение — энтропийный денежный эквивалент:

$$\tilde{\mathbb{E}}^\alpha[X] := -\alpha^{-1} \log \mathbb{E}[e^{-\alpha X}]$$

Интерпретация обозначения:

- Верхний индекс α — коэффициент несклонности к риску
- Нижний индекс (для условных версий $\tilde{\mathbb{E}}_t^\alpha[\cdot]$, $\tilde{\mathbb{E}}_\pi^\alpha[\cdot]$) — относительно чего берётся оператор: фильтрация, стратегия и т.д.
- Тильда над $\mathbb{E}$ подчёркивает: «почти мат.ожидание», но учитывающее риск

Предел $\alpha \rightarrow 0$ (риск-нейтральный): $\tilde{\mathbb{E}}^\alpha[X] \rightarrow \mathbb{E}[X]$ (разложение Тейлора по α).
При $\alpha > 0$ агент осторожничает: $\tilde{\mathbb{E}}^\alpha[X] \leq \mathbb{E}[X]$.

Свойства оператора $\tilde{\mathbb{E}}^\alpha[\cdot]$

- Нормированность: $\tilde{\mathbb{E}}^\alpha[0] = 0$
- Монотонность: $X \leq Y$ п.н. $\Rightarrow \tilde{\mathbb{E}}^\alpha[X] \leq \tilde{\mathbb{E}}^\alpha[Y]$
- Инвариантность к сдвигу: $\tilde{\mathbb{E}}^\alpha[X + c] = \tilde{\mathbb{E}}^\alpha[X] + c, c \in \mathbb{R}$ (cash invariance)
- Телескопическое свойство (tower property): $\tilde{\mathbb{E}}^\alpha[\tilde{\mathbb{E}}^\alpha[Y | X]] = \tilde{\mathbb{E}}^\alpha[Y]$
- Вогнутость: $\tilde{\mathbb{E}}^\alpha[\lambda X + (1 - \lambda)Y] \geq \lambda \tilde{\mathbb{E}}^\alpha[X] + (1 - \lambda) \tilde{\mathbb{E}}^\alpha[Y], \lambda \in [0, 1]$

В отличие от мат.ожидания, $\tilde{\mathbb{E}}^\alpha[\cdot]$ не положительно однороден: $\tilde{\mathbb{E}}^\alpha[cX] \neq c\tilde{\mathbb{E}}^\alpha[X]$.

Вывод. Свойства очень похожи на свойства мат.ожидания. В частности, *инвариантность к сдвигу и телескопическое свойство* — ключевые свойства, на которых построена вся теория RL (оценочные функции, уравнения Беллмана, Q-learning, policy gradient).

$\Rightarrow$ Можно попробовать перестроить теорию и алгоритмы RL, заменив $\mathbb{E}[\cdot] \rightarrow \tilde{\mathbb{E}}^\alpha[\cdot]$.

Постановка risk-averse RL

Идея: в классической постановке RL заменяем $\mathbb{E}[\cdot] \rightarrow \tilde{\mathbb{E}}^\alpha[\cdot]$.

Целевой функционал:

$$\boxed{J(\pi) := \tilde{\mathbb{E}}_{\mathcal{T} \sim \pi}^\alpha[R(\mathcal{T})] \rightarrow \max_{\pi}}, \quad R(\mathcal{T}) = \sum_{t \geq 0} r_t$$

Награда $r_t = r(s_t, a_t, s_{t+1})$ (стохастическая относительно s_t, a_t).

$\gamma = 1$: для простоты (все равно в финансах конечный горизонт часто).

Оценочные функции стратегии π (тильда — отличие от классических):

$$\tilde{V}^\pi(s) := \tilde{\mathbb{E}}_{\mathcal{T} \sim \pi | s_0=s}^\alpha[R(\mathcal{T})], \quad \tilde{Q}^\pi(s, a) := \tilde{\mathbb{E}}_{\mathcal{T} \sim \pi | s_0=s, a_0=a}^\alpha[R(\mathcal{T})]$$

Связь $\tilde{V}$ и $\tilde{Q}$ (из tower property):

$$\tilde{V}^\pi(s) = \tilde{\mathbb{E}}_{a \sim \pi(\cdot|s)}^\alpha[\tilde{Q}^\pi(s, a)] \tag{VQ}$$

$$\tilde{Q}^\pi(s, a) = \tilde{\mathbb{E}}_{s' \sim p(\cdot|s,a)}^\alpha[r(s, a, s') + \tilde{V}^\pi(s')] \tag{QV}$$

Уравнения Беллмана

Подставляя (VQ) и (QV) друг в друга, получаем **уравнения Беллмана**:

VV-уравнение:

$$\tilde{V}^\pi(s) = \tilde{\mathbb{E}}_{a, s'}^\alpha \left[r(s, a, s') + \tilde{V}^\pi(s') \right] \quad (\text{VV})$$

QQ-уравнение:

$$\tilde{Q}^\pi(s, a) = \tilde{\mathbb{E}}_{s'}^\alpha \left[r(s, a, s') + \tilde{\mathbb{E}}_{a'}^\alpha \left[\tilde{Q}^\pi(s', a') \right] \right] \quad (\text{QQ})$$

Интуиция та же, что в классическом RL: « $\tilde{\mathbb{E}}^\alpha[\cdot]$ награды за игру = $\tilde{\mathbb{E}}^\alpha[\cdot]$ награды за шаг + $\tilde{\mathbb{E}}^\alpha[\cdot]$ за остаток». Но теперь пересчёт риск-чувствительный.

Уравнения оптимальности Беллмана

Оптимальные оценочные функции:

$$\tilde{V}^*(s) := \max_{\pi} \tilde{V}^{\pi}(s), \quad \tilde{Q}^*(s, a) := \max_{\pi} \tilde{Q}^{\pi}(s, a).$$

Связь оптимальных функций:

$$\tilde{V}^*(s) = \max_a \tilde{Q}^*(s, a) \quad (V^*Q^*)$$

$$\tilde{Q}^*(s, a) = \tilde{\mathbb{E}}_{s'}^{\alpha} \left[r(s, a, s') + \tilde{V}^*(s') \right] \quad (Q^*V^*)$$

Уравнения оптимальности Беллмана:

$$\tilde{Q}^*(s, a) = \tilde{\mathbb{E}}_{s'}^{\alpha} \left[r(s, a, s') + \max_{a'} \tilde{Q}^*(s', a') \right] \quad (Q^*Q^*)$$

$$\tilde{V}^*(s) = \max_a \tilde{\mathbb{E}}_{s'}^{\alpha} \left[r(s, a, s') + \tilde{V}^*(s') \right] \quad (V^*V^*)$$

План лекции

1. Мотивация
2. Теория полезности
3. Теория осторожного RL
4. Deep Hedging

Постановка задачи хеджирования

Держим *длинную* позицию в деривативе с выплатой $c(S_T)$ в момент T . Хеджируем позицию базовым активом.

Дискретное время: $t = 1, \dots, T$.

Состояние: $s_t = (t, S_t)$, где S_t — цена акции. S_t — марковский процесс (возможно, неоднородный по t), функция переходов $p(S_{t+1} | S_t, t)$.

Действие: $h_t = h(t, S_t) \in \mathbb{R}$ — число акций, удерживаемых с t до $t + 1$.

Награда: пошаговый P&L от хеджа плюс терминальная выплата по деривативу:

$$R = \underbrace{\sum_{t=1}^{T-1} h_t(S_{t+1} - S_t)}_{\text{P\&L хеджа}} + \underbrace{c(S_T)}_{\text{выплата}}$$

Пространства: $\mathcal{S} \subseteq \mathbb{R}_+ \times \{1, \dots, T\}$ (неполное, t включён в состояние), $\mathcal{A} = \mathbb{R}$ (continuous control).

Целевой функционал и цена дериватива

Риск-чувствительный целевой функционал:

$$J(\pi) = \tilde{\mathbb{E}}^\alpha \left[\sum_{t=1}^{T-1} h_t(S_{t+1} - S_t) + c(S_T) \right] \rightarrow \max_{\pi}$$

Интерпретация: $J(\pi^*)$ — денежный эквивалент оптимально захеджированной длинной позиции $\Rightarrow$ максимальная цена, за которую агент готов купить дериватив.

Цена покупки (bid) — берем выплату со знаком «плюс» $+c(S_T)$:

$$p^+(\alpha) = \max_{\pi} \tilde{\mathbb{E}}^\alpha [\sum h_t \Delta S_t + c(S_T)]$$

Цена продажи (ask) — противоположная позиция, знак $c(S_T)$ меняется:

$$p^-(\alpha) = - \max_{\pi} \tilde{\mathbb{E}}^\alpha [\sum h_t \Delta S_t - c(S_T)]$$

Для осторожного агента ($\alpha > 0$): $p^+ \leq p^-$ — ненулевой bid-ask спред.

Предельные случаи $\alpha \rightarrow 0$ и $\alpha \rightarrow \infty$

Риск-нейтральный предел $\alpha \rightarrow 0$: $\tilde{\mathbb{E}}^\alpha[X] \rightarrow \mathbb{E}[X]$.

Возвращаемся к классической постановке.

Предел радикальной осторожности $\alpha \rightarrow \infty$: $\tilde{\mathbb{E}}^\alpha[X] \rightarrow \text{ess inf } X$.

Целевой функционал становится worst-case P&L:

$$J(\pi) \rightarrow \text{ess inf} \left[\sum h_t \Delta S_t + c(S_T) \right] \rightarrow \max_\pi$$

Это — классическая задача **гарантированного хеджирования** (superhedging): ищем стратегию с наилучшим гарантированным P&L в худшем сценарии.

Конечное $\alpha > 0$ — промежуточный режим: частичный хедж, остаточный риск учитывается через экспоненциальную полезность.

Связь с классической теорией

Полный рынок: выплату $c(S_T)$ можно точно реплицировать хеджем. Существует стратегия π^* и константа p^* :

$$\sum h_t^*(S_{t+1} - S_t) + c(S_T) \equiv p^* \quad (\text{детерминированная константа})$$

При $\alpha = \infty$: worst case = best case = p^* — единая безарбитражная цена. *Задача гарантированного хеджирования корректна.*

Неполный рынок: точной репликации нет, остаточный риск неустраним.

- Классическая безрисковая постановка ($\alpha = \infty$): superhedging $\gg$ subhedging — слишком широкие границы, нерабочие для торговли
- **Конечное α через полезность:** даёт единую цену для каждого α и работает там, где безрисковый подход беспомощен

Именно в этом режиме — неполные рынки, конечное α — Deep Hedging наиболее интересен и полезен.

Простейший алгоритм Deep Hedging

Самый прямолинейный подход: policy gradient «в лоб».

1. **Параметризация.** Хеджирующая стратегия — нейросеть $h_{\theta}(t, S_t) \in \mathbb{R}$.
2. **Сэмплы.** Берем N траекторий $S_{1:T}^{(i)}$ из модели рынка. Для каждой считаем P&L:

$$R^{(i)}(\theta) = \sum_{t=1}^{T-1} h_{\theta}(t, S_t^{(i)}) (S_{t+1}^{(i)} - S_t^{(i)}) + c(S_T^{(i)})$$

3. **Мат.ожидание** $\rightarrow$ **выборочное среднее.** Оптимизируем выборочный функционал:

$$\hat{J}(\theta) = -\alpha^{-1} \log \left(\frac{1}{N} \sum_{i=1}^N e^{-\alpha R^{(i)}(\theta)} \right) \longrightarrow \max_{\theta}$$

Градиентный подъём по θ автоградом.

4. **Цена дериватива.** Подставляем Монте-Карло оценку в определение $\tilde{\mathbb{E}}^{\alpha}[\cdot]$:
получаем $\hat{p}^{+} = \hat{J}(\theta^{*})$.

Проблемы простейшего алгоритма

1. Монте-Карло оценка $\tilde{\mathbb{E}}^\alpha[R]$ смещена.

$\frac{1}{N} \sum e^{-\alpha R^{(i)}}$ — несмещённая оценка $\mathbb{E}[e^{-\alpha R}]$. Но $\log$ вогнут; по Йенсену:

$$\mathbb{E}\left[-\alpha^{-1} \log \frac{1}{N} \sum e^{-\alpha R^{(i)}}\right] \geq -\alpha^{-1} \log \mathbb{E}[e^{-\alpha R}] = \tilde{\mathbb{E}}^\alpha[R]$$

Оценка *завышает* функционал (оптимистичное смещение).

2. Зануление градиентов через log-sum-exp.

$\nabla_{\theta} \hat{J} = \sum_i w_i \nabla_{\theta} R^{(i)}$ с softmax-весами $w_i \propto e^{-\alpha R^{(i)}}$. При большом α или широком разбросе $R^{(i)}$ масса концентрируется на траектории с минимальным $R^{(i)}$ — обучающий сигнал от остальных теряется.

3. Цена только в $t = 0$.

$\hat{J}(\theta^*)$ — одно число. Вообще хотелось бы какую-то оценку стоимости иметь для всех состояний. Простейший алгоритм этого не даёт.

V-функция и TD(0): параметризация

Решение проблем: параметризовать $\tilde{V}_\theta^\pi(s)$ нейросетью и обучать по TD(0).

Из (VV):

$$\tilde{V}^\pi(s) = \tilde{\mathbb{E}}_{a,s'}^\alpha[r(s, a, s') + \tilde{V}^\pi(s')] \iff e^{-\alpha\tilde{V}^*(s)} = \mathbb{E}_{s'}[e^{-\alpha(r+\tilde{V}^*(s'))}]$$

Это подсказывает форму регрессии: предсказываем $e^{-\alpha\tilde{V}_\theta(s)}$, таргет $e^{-\alpha(r+\tilde{V}_{\theta^-}(s'))}$.

TD-таргет (с замороженной копией θ^-): $y_V = r + \tilde{V}_{\theta^-}(s')$.

TD-residual (ошибка одного шага):

$$\delta_{\tilde{V}}(\theta) := r(s, a, s') + \tilde{V}_{\theta^-}(s') - \tilde{V}_\theta(s)$$

Остаётся выбрать *функцию потерь* в регрессии. Один очевидный кандидат, плюс один более тонкий.

EMSE: прямолинейный подход и его проблема

Вступую — MSE между экспонентами прогноза и таргета (EMSE):

$$\mathcal{L}^{\text{EMSE}}(\theta) = \frac{1}{2} \mathbb{E}_{(s,a,s')} \left[\left(e^{-\alpha \tilde{V}_\theta(s)} - e^{-\alpha(r + \tilde{V}_{\theta-}(s'))} \right)^2 \right]$$

В оптимуме регрессии: $e^{-\alpha \tilde{V}_\theta(s)} = \mathbb{E}_{s'} [e^{-\alpha(r + \tilde{V}_{\theta-}(s'))}]$ — то самое уравнение Беллмана.

Проблема — масштабная зависимость. Преобразуем:

$$\left(e^{-\alpha \tilde{V}_\theta(s)} - e^{-\alpha(r + \tilde{V}_{\theta-}(s'))} \right)^2 = e^{-2\alpha \tilde{V}_\theta(s)} \left(1 - e^{-\alpha \delta_{\tilde{V}}} \right)^2$$

Множитель $e^{-2\alpha \tilde{V}_\theta(s)}$ зависит от *абсолютного уровня* $\tilde{V}$.

При больших $|\tilde{V}|$ или α — численная нестабильность: градиенты взрываются или исчезают в зависимости от уровня. Хочется лосс, *не зависящий* от уровня, а только от TD-ошибки $\delta_{\tilde{V}}$.

Дивергенция Брегмана

Определение. Для гладкой выпуклой $\varphi: \mathbb{R}_+ \rightarrow \mathbb{R}$:

$$d_\varphi(x, y) := \varphi(x) - \varphi(y) - \langle x - y, \nabla \varphi(y) \rangle \geq 0, \quad d_\varphi(x, y) = 0 \iff x = y$$

Ключевое свойство.

$$\mathbb{E}[X] = \arg \min_y \mathbb{E}[d_\varphi(X, y)] \quad \forall \varphi$$

Более того: дивергенции Брегмана — *исчерпывающий* класс лоссов, для которых оптимумом регрессии является мат.ожидание.

Частные случаи:

- $\varphi(z) = \frac{1}{2}z^2 \Rightarrow d_\varphi(x, y) = \frac{1}{2}(x - y)^2$ — MSE
- $\varphi(z) = -\log z \Rightarrow d_\varphi(x, y) = x/y - \log(x/y) - 1$ — расстояние Итакура-Саито

Итакура-Саито лосс

Подставляем в $d_{IS}(x, y) = x/y - \log(x/y) - 1$:

таргет: $x = e^{-\alpha(r(s,a,s') + \tilde{V}_{\theta-}(s'))}$, прогноз: $y = e^{-\alpha\tilde{V}_{\theta}(s)}$

$$x/y = e^{-\alpha\delta_{\tilde{V}}(\theta)}$$

$$\mathcal{L}^{\text{IS}}(\theta) = \alpha^{-2} \mathbb{E}_{(s,a,s')} \left[e^{-\alpha\delta_{\tilde{V}}(\theta)} + \alpha\delta_{\tilde{V}}(\theta) - 1 \right]$$

Свойства:

- Масштабно-инвариантен: зависит от θ только через $\delta_{\tilde{V}}$, не от уровня $\tilde{V}$
- Корректный оптимум: минимизатор удовлетворяет уравнению Беллмана.
- MSE в пределе малых ошибок: $\mathcal{L}^{\text{IS}} \approx \mathbb{E} \left[\frac{1}{2} \delta_{\tilde{V}}^2 \right]$ по разложению Тейлора. Для этого красивого свойства и поделили на α^2 .

Бонус TD(0): решение проблемы зануления градиентов

Напомним проблему простейшего алгоритма: градиент $\nabla_{\theta} \hat{J}$ содержал log-sum-exp по всей пачке траекторий $\Rightarrow$ softmax-веса концентрировались на худшей траектории.

В IS-лоссе такой проблемы нет. Лосс — обычное мат.ожидание по переходам (s, a, s') :

$$\mathcal{L}^{\text{IS}}(\theta) = \mathbb{E}_{(s,a,s')}[\ell_{\text{IS}}(\delta_{\tilde{V}}(\theta))]$$

Каждый переход вносит независимый вклад, масса не стягивается в одну точку.

Причина: log-sum-exp оператор $\tilde{\mathbb{E}}^{\alpha}[\cdot]$ теперь применён на каждом шаге отдельно (через экспоненциальное уравнение Беллмана), а не к целой траектории — нелинейность «рассыпалась» по шагам.

То есть TD(0)-формулировка не только даёт $\tilde{V}(t, S_t)$ во всех состояниях, но заодно лечит проблему затухания градиентов.

Обучение хеджирующей стратегии

Параметризуем стратегию $\pi_\phi(s)$ нейросетью. Оптимальная стратегия детерминирована: $h_t = \pi_\phi(t, S_t)$ — число акций.

Цель: максимизировать $\tilde{Q}^\pi(s, \pi_\phi(s))$. По (QV):

$$\tilde{Q}^\pi(s, a) = -\alpha^{-1} \log \mathbb{E}_{s'} \left[e^{-\alpha(r + \tilde{V}_\theta^\pi(s'))} \right]$$

Так как $-\alpha^{-1} \log(\cdot)$ монотонно убывает, максимизация по ϕ эквивалентна минимизации $\mathbb{E}_{(s,a,s')} [e^{-\alpha(r + \tilde{V}_\theta^\pi(s'))}]$. Вычитая из-под экспоненты $\tilde{V}_\theta^\pi(s)$ (константа по ϕ) как бейзлайн для численной стабильности:

$$\mathcal{L}_\pi(\phi) = \alpha^{-1} \mathbb{E}_{s'} \left[e^{-\alpha(r(s, \pi_\phi(s), s') + \tilde{V}_\theta^\pi(s') - \tilde{V}_\theta^\pi(s))} \right]$$

Под экспонентой — TD-residual относительно стратегии π_ϕ . Лосс штрафует стратегии, по которым TD-residual отрицателен (просадка) экспоненциально, а поощряет положительный TD-residual слабо — в точности ожидаемое осторожное поведение.

Разреженная награда и reward shaping

Проблема. В хедже награда почти вся сосредоточена в одном шаге: выплата $c(S_T)$ приходит только в конце эпизода. Промежуточные $h_t \Delta S_t$ — мелкие флуктуации вокруг нуля. Сигнал для обучения разреженный, сходимость медленная.

Решение — reward shaping. Потенциал $\Phi(t, S_t)$ — *стоимость будущих выплат* в какой-то разумной модели ценообразования. Пример: цена в модели Блэка-Шоулза с какой-то оценкой волатильности.

Тогда $\Phi(T, S_T) = 0$ *естественно*: в момент T выплата $c(S_T)$ уже произведена, будущих выплат нет $\Rightarrow$ стоимость будущих выплат нулевая. Это согласуется с требованием теоремы reward shaping.

Новая награда:

$$r_t^{\text{new}} = r_t + \Phi(t + 1, S_{t+1}) - \Phi(t, S_t)$$

Выплата $c(S_T)$ никуда не исчезает: она по-прежнему входит в r_{T-1} , а $\Phi(T, S_T) = 0$ означает, что в момент T прокси-стоимость дериватива падает на размер выплаты.

Интерпретация reward shaping

Приращение Φ за один шаг из уравнения Блэка-Шоулза можно записать как:

$$\Phi(t+1, S_{t+1}) - \Phi(t, S_t) \approx \Delta_t(S_{t+1} - S_t), \quad \Delta_t = \partial_S \Phi(t, S_t)$$

(Δ_t — дельта длинной позиции; в непрерывном пределе равенство точное).

Подставляя:

$$r_t^{\text{new}} \approx (h_t + \Delta_t)(S_{t+1} - S_t)$$

Интерпретация. Длинная позиция в деривативе хеджируется шортом Δ_t акций $\Rightarrow$ оптимум $h_t^* = -\Delta_t$. Тогда $h_t + \Delta_t = h_t - h_t^*$ — отклонение от дельта-хеджа. На оптимуме $r_t^{\text{new}} \approx 0$, любое отклонение даёт ненулевой шумовой сигнал $\Rightarrow$ плотное обучение на каждом шаге.

Важно. Φ не обязан быть ценой по истинной модели. Любая разумная формула (BS с приближённой волатильностью и т.п.) даёт ускорение сходимости; π^* не меняется.

Итоговый алгоритм и цена дериватива

Actor-critic цикл. Повторяем:

- Симулируем переходы (s, a, r, s') , $a = \pi_\phi(s)$, из модели рынка
- Считаем награду за каждый шаг с использованием какой-то прокси-модели
- Шаг градиентного спуска по θ на $\mathcal{L}^{\text{IS}}$ — обновление $\tilde{V}_\theta^\pi$
- Шаг градиентного спуска по ϕ на $\mathcal{L}_\pi$ — обновление хеджирующей стратегии π_ϕ

Цена дериватива — оценка $\tilde{V}_\theta^\pi$ в стартовом состоянии:

$$\hat{p}^+ = \tilde{V}_\theta^\pi(0, S_0)$$

Причём одновременно получаем $\tilde{V}_\theta^\pi(t, S_t)$ во всех состояниях $\Rightarrow$ можем оценить стоимость позиции в каждый момент времени.

Вопросы?