

Машинное обучение в финансах

Лекция 5: Deep Hedging и Робастные Финансы

Игорь Удовиченко

Факультатив Веги

24 апреля 2026 г.

План лекции

1. Оптимальный транспорт в финансах
2. RERMOT и Deep Hedging
3. Калибровка и декомпозиция задачи

План лекции

1. Оптимальный транспорт в финансах

2. RERMOT и Deep Hedging

3. Калибровка и декомпозиция задачи

Риск неправильной модели

Стандартный пайплайн расчета цены ОТС дериватива $c(S)$:

1. выбрать модель рынка (Black–Scholes, Heston, local vol, rough vol, ...);
2. откалибровать её параметры к рыночным ценам ванили;
3. посчитать цену и риски в модели.

Проблема. Две разные модели, одинаково хорошо откалиброванные к рынку, могут давать *сильно разные цены* path-dependent экзотики. Выбор модели — спекулятивное предположение, которое нельзя проверить по доступной рыночной информации.

Model-free pricing (Hobson, 1998)

Найти **наихудший случай** среди всех моделей, откалиброванных к рынку. Нижняя/верхняя робастная граница цены — без выбора конкретной модели.

Формула Breeden–Litzenberger

Цена европейского колла со страйком K и сроком T :

$$C(K, T) = \mathbb{E}^{\mathbb{Q}}[(S_T - K)^+]$$

Дифференцируем по K :

$$\partial_K C(K, T) = -\mathbb{Q}(S_T > K), \quad \partial_K^2 C(K, T) = \mu_T(K)$$

где μ_T — плотность распределения S_T под $\mathbb{Q}$.

Breeden–Litzenberger (1978)

Непрерывный по страйку спектр цен ванили однозначно определяет **маргинальное распределение** S_T в риск-нейтральной мере: $\mu_T = \partial_K^2 C(\cdot, T)$.

Если на рынке торгуются ваниль со сроками $T_1, \dots, T_M$, то мы наблюдаем **весь набор маргиналов** $\{\mu_m\}_{m=1}^M$. Это и есть та рыночная информация, к которой должна быть откалибрована модель.

Классический оптимальный транспорт

Задача Монжа/Канторовича: перевести массу μ в массу ν с минимальной стоимостью $c(x, y)$ перемещения $x \rightarrow y$.

Прямая задача:

$$\inf_{\pi \in \Pi(\mu, \nu)} \int c(x, y) d\pi(x, y), \quad \Pi(\mu, \nu) = \{\pi : \pi_1 = \mu, \pi_2 = \nu\}$$

— инфимум по *каплингам* π с заданными маргиналами.

Двойственная задача:

$$\sup_{\varphi, \psi} \left\{ \int \varphi d\mu + \int \psi d\nu : \varphi(x) + \psi(y) \leq c(x, y) \right\}$$

— супремум по *потенциалам* φ, ψ . Сильная двойственность: прямая = двойственной.

Финансовая аналогия уже тут:

- каплинг $\pi \leftrightarrow$ совместное распределение цен в разные сроки (процесс цены);
- потенциалы $\varphi, \psi \leftrightarrow$ статическая хеджирующая позиция.

Мартингальный оптимальный транспорт

В финансах к ограничениям на маргиналы добавляется еще одно условие — цена базового актива должна быть мартингалом в риск-нейтральной мере.

MOT (Beiglböck, Henry-Labordère, Penkner, 2013):

$$\mathcal{M} = \left\{ \mathbb{P} : S_{T_m} \sim \mu_m, m = 1, \dots, M; S \text{ — } \mathbb{P}\text{-мартингал} \right\}. \quad \inf_{\mathbb{P} \in \mathcal{M}} \mathbb{E}^{\mathbb{P}}[c(S)], \quad (\text{MOT})$$

Финансовый смысл:

- μ_m из Breeden–Litzenberger $\Rightarrow$ модель скалирована к ванили во все сроки T_m ;
- мартингальность — можем торговать акцией S ;
- $\inf / \sup \mathbb{E}^{\mathbb{P}}[c(S)] \Rightarrow$ **нижняя/верхняя робастная цена** дериватива.

Для специальных c (lookback, forward-start) есть явные решения (Hobson, Cox–Obłój).
Для общих path-dependent c — только численно.

Энтропийная регуляризация (ERMOT)

Дискретизируем пространство траекторий на конечной сетке $\Rightarrow$ MOT становится **линейным программированием** над вероятностями узлов сетки.

Проблема: число переменных $\sim |\text{сетка}|^T$ — экспоненциально по числу шагов.

Идея (Cuturi, 2013) — добавить энтропийную регуляризацию:

$$\inf_{\mathbb{P} \in \mathcal{M}} \left\{ \mathbb{E}^{\mathbb{P}}[c(S)] - \frac{1}{\alpha} H(\mathbb{P}) \right\}, \quad H(\mathbb{P}) = - \sum_{\omega} \mathbb{P}(\omega) \log \mathbb{P}(\omega). \quad (\text{ERMOT})$$

- *Строго выпуклая* задача $\Rightarrow$ единственное решение, численная корректность.
- Двойственная задача решается итеративно (Sinkhorn-подобные алгоритмы).
- Сложность растет *линейно* по T .
- $\alpha \rightarrow \infty$: регуляризация исчезает, возвращаемся к (MOT).

Следующий шаг: энтропия $H(\mathbb{P}) \rightarrow$ относительная энтропия $H(\mathbb{P} \parallel \mathbb{Q})$ с prior $\mathbb{Q}$;
дискретная сетка $\rightarrow$ непрерывные пространства с нейросетевой параметризацией.

План лекции

1. Оптимальный транспорт в финансах

2. RERMOT и Deep Hedging

3. Калибровка и декомпозиция задачи

Постановка задачи: RERMOT

Задача робастного оценивания дериватива с выплатой $c(S)$ (возможно, path-dependent): ищем наихудшую (для продавца) модель рынка при ограничениях, заданных рыночными ценами торгуемых инструментов.

Relative Entropy-Regularized MOT:

$$\inf_{\mathbb{P} \in \mathcal{P}} \left\{ \mathbb{E}^{\mathbb{P}}[c(S)] + \frac{1}{\alpha} H(\mathbb{P} \parallel \mathbb{Q}) \right\}, \quad (\text{RERMOT})$$

$$\mathcal{P} = \{ \mathbb{P} : \mathbb{E}^{\mathbb{P}}[g_k(S)] = p_k, \ k = 1, \dots, K; \ S \text{ — } \mathbb{P}\text{-мартингал} \}.$$

- $\mathbb{Q}$ — априорная модель рынка (в пределе $\alpha \rightarrow \infty$ регуляризация уходит)
- $H(\mathbb{P} \parallel \mathbb{Q})$ — относительная энтропия (KL-дивергенция); обеспечивает строгую выпуклость $\Rightarrow$ задача всегда корректна
- $\{g_k, p_k\}$ — торгуемые инструменты (ваниль) с рыночными ценами
- Мартингальность $S \Leftrightarrow$ отсутствие арбитража в модели $\mathbb{P}$

Решение обозначим $\mathbb{P}^*$, оптимум функционала V^* .

Двойственная задача: множители Лагранжа

Вводим множители для обоих типов ограничений:

- h — процесс, адаптированный к фильтрации S_t (потом станет стратегией хеджирования);
 $h \cdot S := \sum_{t=0}^{T-1} h_t \Delta S_t$ — мартингальное условие $\mathbb{E}^{\mathbb{P}}[h \cdot S] = 0$
- $\mathbf{q} = (q_1, \dots, q_K) \in \mathbb{R}^K$ — множители для ценовых ограничений

$$V^* = \inf_{\mathbb{P}} \sup_{h, \mathbf{q}} \left\{ \mathbb{E}^{\mathbb{P}}[c(S)] + \frac{1}{\alpha} H(\mathbb{P} \parallel \mathbb{Q}) + \mathbb{E}^{\mathbb{P}}[h \cdot S] + \sum_{k=1}^K q_k (\mathbb{E}^{\mathbb{P}}[g_k(S)] - p_k) \right\}$$

После перестановки $\inf$ и $\sup$ внутренняя задача по $\mathbb{P}$ решается явно:

$$\frac{d\mathbb{P}^*}{d\mathbb{Q}} = \frac{1}{Z(h, \mathbf{q})} \exp \left\{ -\alpha \left(c(S) + h \cdot S + \sum_{k=1}^K q_k (g_k(S) - p_k) \right) \right\}$$

где $Z(h, \mathbf{q}) = \mathbb{E}^{\mathbb{Q}}[\exp\{-\alpha(\dots)\}]$ — нормировочная константа.

Двойственная задача (RERD) = Deep Hedging

Подставляя $d\mathbb{P}^*/d\mathbb{Q}$ обратно, получаем двойственную задачу:

$$V_{\mathbb{Q}}^* = \sup_{h, \mathbf{q}} \left\{ -\frac{1}{\alpha} \log Z(h, \mathbf{q}) \right\} = \sup_{h, \mathbf{q}} \tilde{\mathbb{E}}_{\mathbb{Q}}^{\alpha} \left[c(S) + h \cdot S + \sum_{k=1}^K q_k (g_k(S) - p_k) \right] \quad (\text{RERD})$$

где $\tilde{\mathbb{E}}_{\mathbb{Q}}^{\alpha}[\xi] = -\alpha^{-1} \log \mathbb{E}^{\mathbb{Q}}[e^{-\alpha \xi}]$ — энтропийный денежный эквивалент.

Но это в точности Deep Hedging из прошлой лекции!

- $c(S)$ — выплата длинной позиции в деривативе
- $h \cdot S$ — P&L динамического хеджа в базовом активе
- $\sum q_k (g_k(S) - p_k)$ — P&L статических позиций q_k в торгуемых опционах

Параметризуем h нейросетью $\Rightarrow$ Deep Hedging под априорной моделью $\mathbb{Q}$.

Алгоритм: актер-критик (resap)

В общем случае cash flow от хеджа + статических позиций + дериватива марковские в некотором состоянии X_t (включая t , цену S_t , и всё, что нужно для опционов).

Тогда:

$$V_{\mathbb{Q}}^* = \sup_{h, \mathbf{q}} \tilde{\mathbb{E}}_{\mathbb{Q}}^{\alpha} \left[\sum_{t=0}^{T-1} \text{PnL}_t(X_t \mid h_t, \mathbf{q}) \right]$$

Алгоритм с прошлой лекции применяется без изменений (для фиксированного $\mathbf{q}$):

- $\tilde{V}_{\theta}(t, X_t \mid h, \mathbf{q})$ — критик (нейросеть), обучаем по IS-лоссy:

$$\mathcal{L}^{\text{IS}}(\theta) = \alpha^{-2} \mathbb{E} \left[e^{-\alpha \delta_V} + \alpha \delta_V - 1 \right], \quad \delta_V = \text{PnL}_t + \tilde{V}_{\theta-}(t+1) - \tilde{V}_{\theta}(t)$$

- $h_{\phi}(t, X_t)$ — актер, обучаем по экспоненциальному лоссy на TD-residual

$$\mathcal{L}_h(\phi) = \alpha^{-1} \mathbb{E} \left[e^{-\alpha (\text{PnL}_t(X_t \mid h_{\phi}, \mathbf{q}) + \tilde{V}_{\theta}(t+1) - \tilde{V}_{\theta}(t))} \right]$$

- Reward shaping через прокси-модель цены $\rightarrow$ плотная награда.

Проблема с оптимизацией $\mathbf{q}$

Попробуем обучить $\mathbf{q}$ тем же актор-критиком. Что мешает?

$\mathbf{q}$ — статический параметр, не процесс. Актор $h_\phi(t, X_t)$ — функция состояния: в каждом состоянии своё действие. А $\mathbf{q} \in \mathbb{R}^K$ — *один* вектор для всей траектории и для всех траекторий.

Решение — градиент по $\mathbf{q}$ считать, оптимизируя исходный функционал:

$$\tilde{\mathbb{E}}_{\mathbb{Q}}^{\alpha} \left[c(S) + h \cdot S + \sum_{k=1}^K q_k (g_k(S) - p_k) \right]$$

Получаем 3 оптимизации в одном:

1. Обучаем V-функцию $\tilde{V}_\theta$.
2. Обучаем динамическое хеджирование h_ϕ .
3. Оптимизируем позицию в ванили $\mathbf{q}$.

План лекции

1. Оптимальный транспорт в финансах
2. RERMOT и Deep Hedging
3. Калибровка и декомпозиция задачи

Выбор априорной модели: теорема Пифагора

Энтропийная регуляризация **вводит смещение** в цену. Хотим его минимизировать.

Теорема Пифагора для относительной энтропии (Csiszár, 1975):


$$H(\mathbb{P} \parallel \mathbb{Q}) \geq H(\mathbb{P} \parallel \mathbb{Q}^*) + H(\mathbb{Q}^* \parallel \mathbb{Q}), \quad (\text{Pyth})$$

где $\mathbb{Q}^*$ — KL-проекция $\mathbb{Q}$ на $\mathcal{P}$:

$$\mathbb{Q}^* = \arg \min_{\tilde{\mathbb{Q}} \in \mathcal{P}} H(\tilde{\mathbb{Q}} \parallel \mathbb{Q}). \quad (\text{Proj})$$

Ограничения $\mathcal{P}$ **линейные** $\Rightarrow$ (Pyth) достигается с равенством.

Взяв $\mathbb{Q}^*$ как prior, сокращаем смещение регуляризации ровно на $H(\mathbb{Q}^* \parallel \mathbb{Q})$.



Калибровка модели

Задача KL-проекции $\mathbb{Q}^* = \arg \min_{\tilde{\mathbb{Q}} \in \mathcal{P}} H(\tilde{\mathbb{Q}} \parallel \mathbb{Q})$ развёрнуто:

$$\inf_{\mathbb{P} \in \mathcal{P}} \frac{1}{\alpha} H(\mathbb{P} \parallel \mathbb{Q}), \quad \mathcal{P} = \{\mathbb{P} : \mathbb{E}^{\mathbb{P}}[g_k(S)] = p_k; S - \mathbb{P}\text{-мартингал}\}. \quad (\text{MC})$$

Тот же RERMOT без $c(S) \Rightarrow$ тот же пайплайн.

Двойственная задача:

$$V_*^c = \sup_{h^c, \mathbf{q}^c} \tilde{\mathbb{E}}_{\mathbb{Q}}^{\alpha} \left[\sum_{t=0}^{T-1} \text{PnL}_t^c(X_t \mid h_t^c, \mathbf{q}^c) \right]$$

Интерпретация: V_*^c — величина статистического арбитража на рынке под $\mathbb{Q}$ с заданными ценами $\{p_k\}$.

Плотность проекции восстанавливается из V^c (Radon–Nikodym процесс):

$$-\frac{1}{\alpha} \log \frac{d\mathbb{Q}^*}{d\mathbb{Q}} \Big|_t = \sum_{s=0}^{t-1} \text{PnL}_s^c + V^c(t, X_t) - V^c(0, X_0)$$

$(h^c, \mathbf{q}^c, V_*^c)$ считаем **один раз** тем же актор-критиком.

Декомпозиция: стат. арбитраж + чистый хедж

Подставляем $\mathbb{Q}^*$ как prior в RERMOT и делаем замену меры $\mathbb{Q}^* \rightarrow \mathbb{Q}$:

$$\begin{aligned} V_{\mathbb{Q}^*}^* &= \sup_{h, \mathbf{q}} \tilde{\mathbb{E}}_{\mathbb{Q}^*}^\alpha [\sum_t \text{PnL}_t(X_t \mid h_t, \mathbf{q})] \\ &= \sup_{h, \mathbf{q}} \left\{ -\frac{1}{\alpha} \log \mathbb{E}^{\mathbb{Q}} \left[\frac{d\mathbb{Q}^*}{d\mathbb{Q}} \exp\{-\alpha \sum_t \text{PnL}_t(X_t \mid h_t, \mathbf{q})\} \right] \right\} \\ &= \sup_{h, \mathbf{q}} \tilde{\mathbb{E}}_{\mathbb{Q}}^\alpha [\sum_t \text{PnL}_t(X_t \mid h_t^c + h_t, \mathbf{q}^c + \mathbf{q})] - V_*^c \end{aligned}$$

Подстановка $d\mathbb{Q}^*/d\mathbb{Q}$ возвращает PnL^c под экспоненту (аддитивность по хеджам и позициям), V_*^c вылезает наружу как константа.

Оптимизация под $\mathbb{Q}^*$ даёт **чистую** стратегию $(h, \mathbf{q})$ и **чистую** цену $V_{\mathbb{Q}^*}^*$.
Полная стратегия: $(h^c + h, \mathbf{q}^c + \mathbf{q})$; стат. арбитраж V_*^c отделён.

Сравнение цен

Пусть $\mathbb{Q}$ уже скалиброван: $\mathbb{Q} \in \mathcal{P}$. 4 «цены»:

- (a) $\mathbb{E}^{\mathbb{Q}}[c]$ — цена в prior;
- (b) $V^* = \inf_{\mathbb{P} \in \mathcal{P}} \{ \mathbb{E}^{\mathbb{P}}[c] + \frac{1}{\alpha} H(\mathbb{P} \parallel \mathbb{Q}) \}$ — минимум в (RERMOT);
- (c) $\mathbb{E}^{\mathbb{P}^*}[c]$ — матожидание при $\mathbb{P}^* = \arg \min$ (RERMOT);
- (d) $V_{\text{MOT}}^* = \inf_{\mathbb{P} \in \mathcal{P}} \mathbb{E}^{\mathbb{P}}[c]$ — нерегуляризованная (MOT);

По убыванию

$$\underbrace{\mathbb{E}^{\mathbb{Q}}[c]}_{(a)} \geq \underbrace{V^*}_{(b)} \geq \underbrace{\mathbb{E}^{\mathbb{P}^*}[c]}_{(c)} \geq \underbrace{V_{\text{MOT}}^*}_{(d)}$$

Вопросы?